Aprendizaje Profundo

Facultad de Ingeniería
Universidad de Buenos Aires

Profesores:

Marcos Maillot
Maximiliano Torti

Introducción

- Materia de 8 clases teórico-prácticas
- Trabajamos con diapositivas
- Clases dinámicas, la participación es muy bien recibida
- Clases:
  - 10 minutos resumen de clase anterior
  - 3 bloques de 50 minutos de trabajo teórico-práctico
  - 2 bloques de 10 minutos de descanso
  - Ejercicios clase a clase de práctica (sin nota)

Introducción

- **APROBACIÓN**
  - Examen teórico-práctico offline
  - Se envía el enunciado en la clase 7
  - Fecha límite de entrega 10 días posteriores al final de la cursada
  - La entrega consiste en un Jupyter Notebook o Colab en Github
  - Examen individual
  - *Resolver los ejercicios clase a clase simplifica el examen final*

- Se aprecia el feedback de las clases

Introducción

- Canal de Slack:
  - deep_learning: https://ceaiworkspace.slack.com/archives/C019FT6NYCE
- Repositorio de videos de las clases
- Repositorio de la materia
  - Github: https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/aprendizaje_profundo
- Correos
  - Marcos Maillot: marcos_maillot@yahoo.com.ar
  - Maximiliano Torti: maxit1992@gmail.com

Contenido

- **Clase 1**: Introducción a Deep Learning. Redes feed-forward
- **Clase 2**: Funciones de pérdida y optimización, activación, funciones de salida
- **Clase 3**: Pytorch
- **Clase 4**: Regularización, hyperparameter tunning, embedding layer
- **Clase 5**: Convolutional Neural Networks
- **Clase 6**: Recurrent Neural Networks. Attention Layers
- **Clase 7**: Encoder-Decoder. Autoencoder. Transfer learning
- **Clase 8**: Generative Adversarial Networks

Referencias

Bibliografía solo a modo de sugerencia y no será obligatorio el uso de dicho material. La materia es completamente autocontenida.

- Deep Learning. Ian Goodfellow. https://www.deeplearningbook.org/

Herramientas de trabajo

- Lenguaje de programación:
  - Python 3.8
  - Pip / Conda para instalar paquetes y dependencias
- Librerías principales:
  - Numpy, Pandas, Scikit-Learn, Scipy
  - **Pytorch**
- Consola interactiva:
  - **iPhyton y Google Colab**
  - (Opcional) Jupyter Notebook
- Herramientas:
  - Github para repositorios
- IDE:
  - VSCode o PyCharm

Introducción a Deep Learning

- Loss function
  - Error cuadrático medio (ECM)
  - Binary Cross Entropy
  - Cross Entropy
  - KL-Divergence
  - Dice loss
- Model Architecture
  - Non-linear neural network
    - Layers: Linear, Convolutional, Recurrent
    - Activation Function: Sigmoid, Softmax, ReLu, Tanh
    - # of layers, # of hidden units
- Optimization
  - Algorithms
    - Gradient Descent
- Metrics

Introducción a Deep Learning

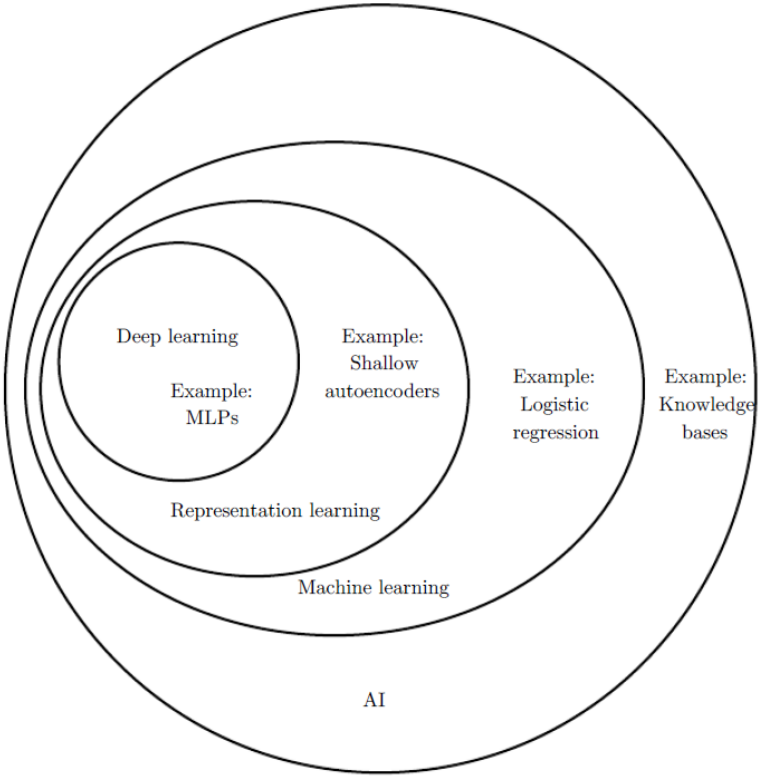

Diagrama de Venn de algoritmos

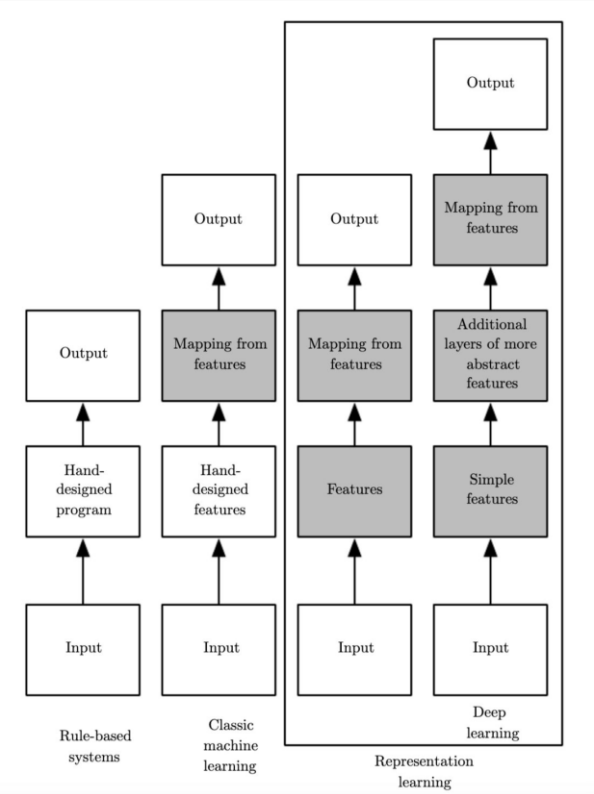

Enfoques de soluciones

Redes neuronales:

- Aprendizaje end to end.

- Aprenden composiciones

Ejemplo de solución con Deep Learning

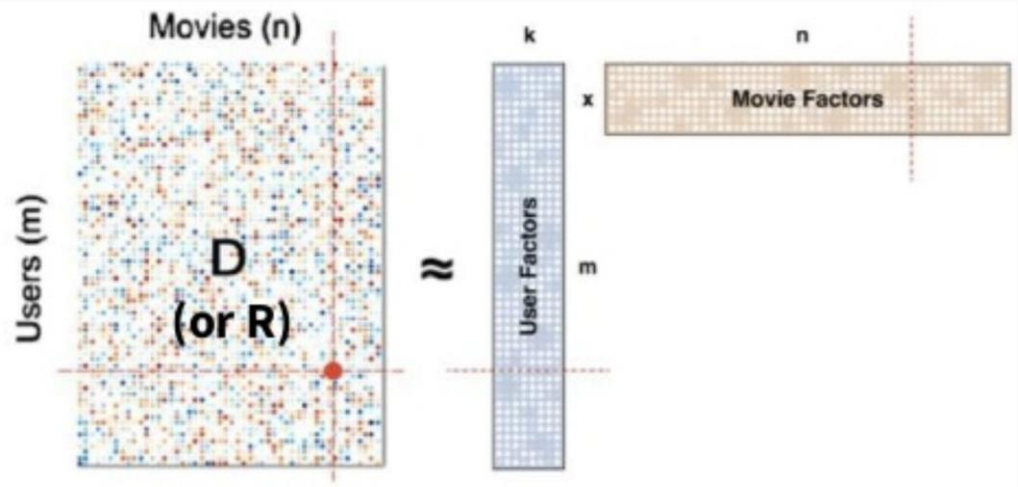

- El objetivo es aprender todos los Uu e Ii.
- Uu e Ii son representaciones densas de usuarios y películas.

	Pelicula	Monster Ink	Spider-Man	Inception	...
	Ii	2.95	2,03	0.98	...
		-0,73	0,33	1,03	...

Usuario	Uu	
Cosme	3,9	4,1
Fulanito	2	5
...	...	...

8,51	9,27	8,045	...
2,25	5,71	7,11	...
...	...	...	...

Ejemplo de solución con Deep Learning

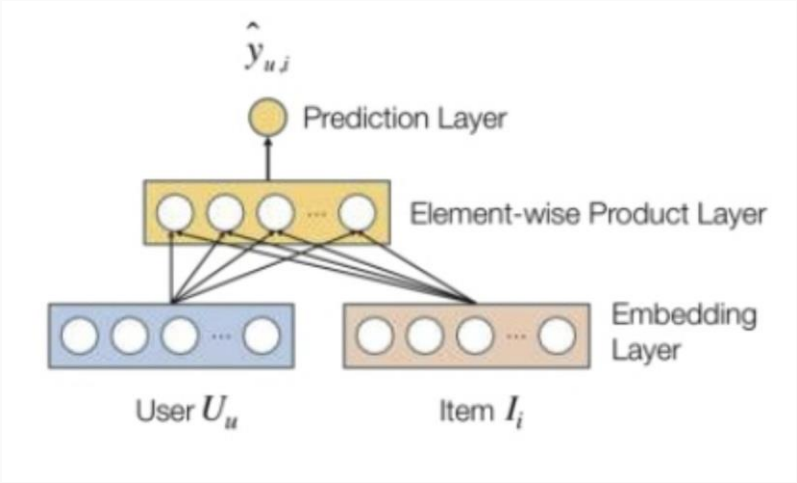

$$L = \sum_{u,i} (R_{u,i} - U_u I_i)^2$$

$$\nabla L = \nabla \left(\sum_{u,i} (R_{u,i} - U_u I_i)^2 \right)$$

- Lo que aprendemos son los “embeddings” de los usuarios y los “embeddings” de las películas.
- Producto interno entre Uu e Ii como arquitectura.
- ECM como función de costo.
- Gradient Descent como optimización.
- Podríamos utilizar una red neuronal para resolver el problema.

Ejemplo de solución con Deep Learning

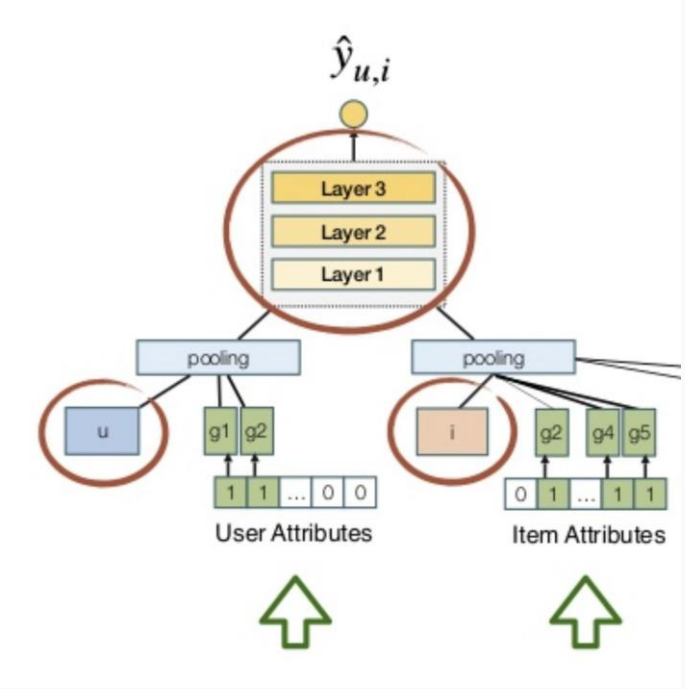

$$L = \sum_{u,i} \left(R_{u,i} - f(U_u, I_i, g_1, g_2, \ldots, g_5)\right)^2$$

$$\nabla L = \nabla \left(\sum_{u,i} \left(R_{u,i} - f(U_u, I_i, g_1, g_2, \ldots, g_5)\right)^2 \right)$$

- Solución más cercana a una solución real, con una red neuronal compleja.
- Múltiples entradas de diferentes dominios -> Las redes neuronales son multimodales.
- Los elementos encerrados en rojo son los parámetros entrenables.

Feed-Forward neural network

Feed-Forward neural network

¿Por qué necesitamos modelos no lineales?

- Caso simple: Compuerta XOR

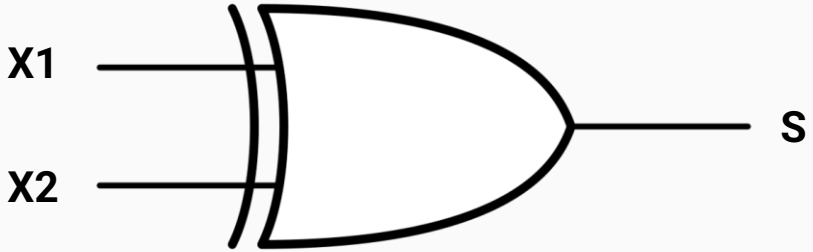

X1	X2	S
0	0	0
0	1	1
1	0	1
1	1	0

X_i X_B $X_{i,j}$ X y

$Nomenclatura:$

- $\vec{X} \rightarrow dataset\ de\ entrada \in R^{n \times m}$
- $\vec{y} \rightarrow salida \in R^{n \times 1}$
- $m \rightarrow cantidad\ de\ columnas,\ n \rightarrow cantidad\ de\ filas$
- $X_{i,j} \rightarrow parámetro\ j\ de\ la\ muestra\ i \in R$
- $\vec{X}_i \rightarrow vector\ de\ la\ fila\ i \in R^{1 \times m}$
- $\vec{X}_b \rightarrow matriz\ de\ batch \in R^{b \times m}$

Feed-Forward neural network

- Arquitectura: Modelo Lineal

$$\hat{f} \ : \ R^2 \rightarrow R / \hat{y}_i = \hat{f}\left(X_{i,1}, X_{i,2}\right) = W_1 \cdot X_{i,1} + W_2 \cdot X_{i,2} + b$$

- Loss function: Error cuadrático medio

$$L\left(W_1, W_2, b, \vec{X}, \vec{y}\right) = L(W_1, W_2, b) = \frac{1}{4} \cdot \sum_{i=1}^{4} \left(y_i - \hat{y}_i\right)^2$$

- Optimizador: Solución cerrada

$$\vec{\nabla}_{\vec{w}} L = \vec{0} \rightarrow \vec{\nabla}_{\vec{w}} L = \begin{Bmatrix} \frac{\partial L}{\partial W_1} \\ \frac{\partial L}{\partial W_2} \\ \frac{\partial L}{\partial b} \end{Bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\vec{W} = \begin{bmatrix} W_1 \\ W_2 \\ b \end{bmatrix} = \left(\vec{X}^T \cdot \vec{X}\right)^{-1} \cdot \vec{X}^T \cdot \vec{y} \rightarrow \vec{W} = \begin{bmatrix} 0 \\ 0 \\ 0.5 \end{bmatrix}$$

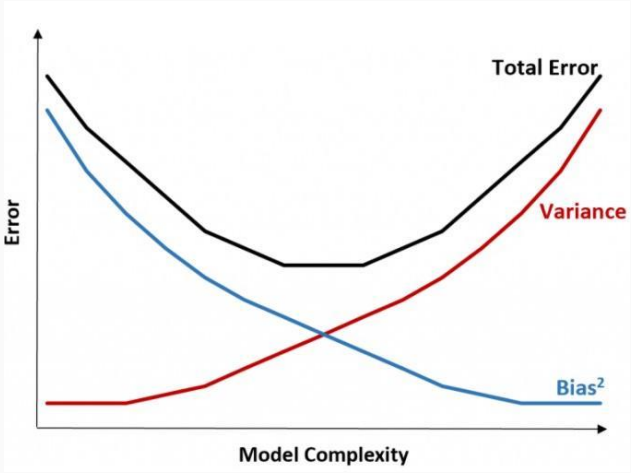

Neurona

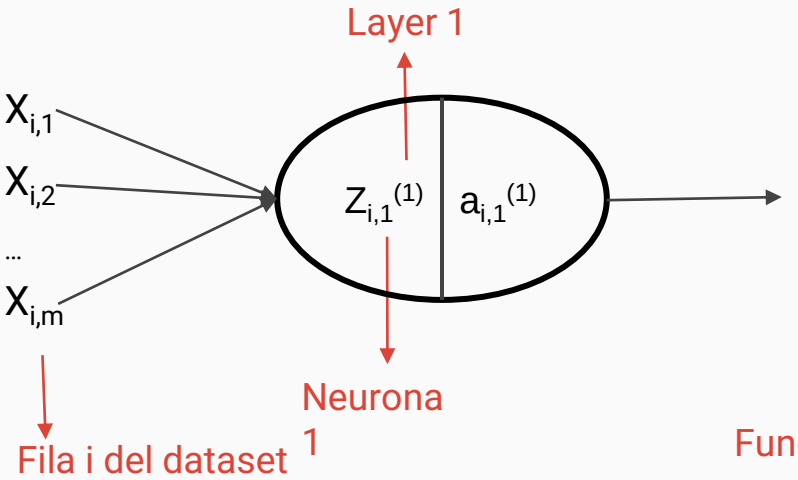

$$Z_{i,1}^{(1)} = W_{1,1}^{(1)} \cdot X_{i,1} + W_{1,2}^{(1)} \cdot X_{i,2} + \ldots + W_{1,m}^{(1)} \cdot X_{i,m} + b_1^{(1)}$$

$$a_{i,1}^{(1)} = \sigma\left(Z_{i,1}^{(1)}\right)$$

Función de activación:

- Sigmoid
- ReLU
- Tanh
- Softmax

Layer Lineal con función de activación

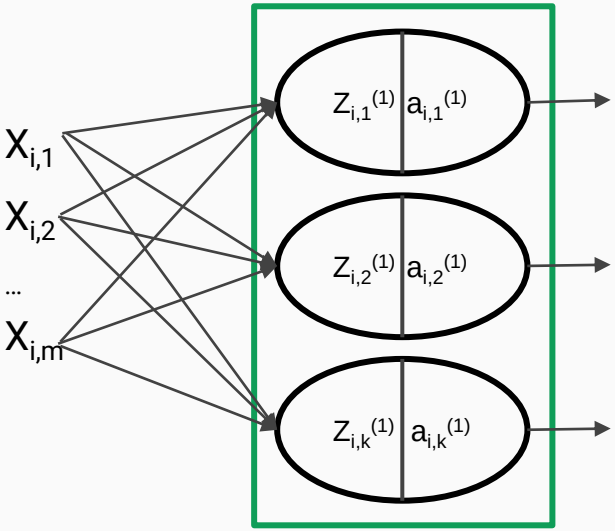

Layer 1

$$a_{i,1}^{(1)} = \sigma\left(Z_{i,1}^{(1)}\right) = \sigma\left(W_{1,1}^{(1)} \cdot X_{i,1} + W_{1,2}^{(1)} \cdot X_{i,2} + \ldots + W_{1,m}^{(1)} \cdot X_{i,m} + b_1^{(1)}\right)$$

$$a_{i,2}^{(1)} = \sigma\left(Z_{i,2}^{(1)}\right) = \sigma\left(W_{2,1}^{(1)} \cdot X_{i,1} + W_{2,2}^{(1)} \cdot X_{i,2} + \ldots + W_{2,m}^{(1)} \cdot X_{i,m} + b_2^{(1)}\right)$$

$$a_{i,k}^{(1)} = \sigma\left(Z_{i,k}^{(1)}\right) = \sigma\left(W_{k,1}^{(1)} \cdot X_{i,1} + W_{k,2}^{(1)} \cdot X_{i,2} + \ldots + W_{k,m}^{(1)} \cdot X_{i,m} + b_k^{(1)}\right)$$

En formato matricial:

$$\vec{A}_i^{(1)} = \sigma\left(\vec{Z}_i^{(1)}\right) = \sigma\left(\vec{W}^{(1)} \cdot \vec{X}_i + \vec{b}^{(1)}\right)$$

$$\#\, de\, parámetros:\ k \times (m+1)$$

$$\vec{A}_i^{(1)}, \vec{Z}_i^{(1)} \in R^{k \times 1}$$

$$\vec{W}^{(1)} \in R^{k \times m}$$

$$\vec{X}_i \in R^{m \times 1}$$

$$\vec{b}^{(1)} \in R^{k \times 1}$$

Red neuronal feedforward con p layers

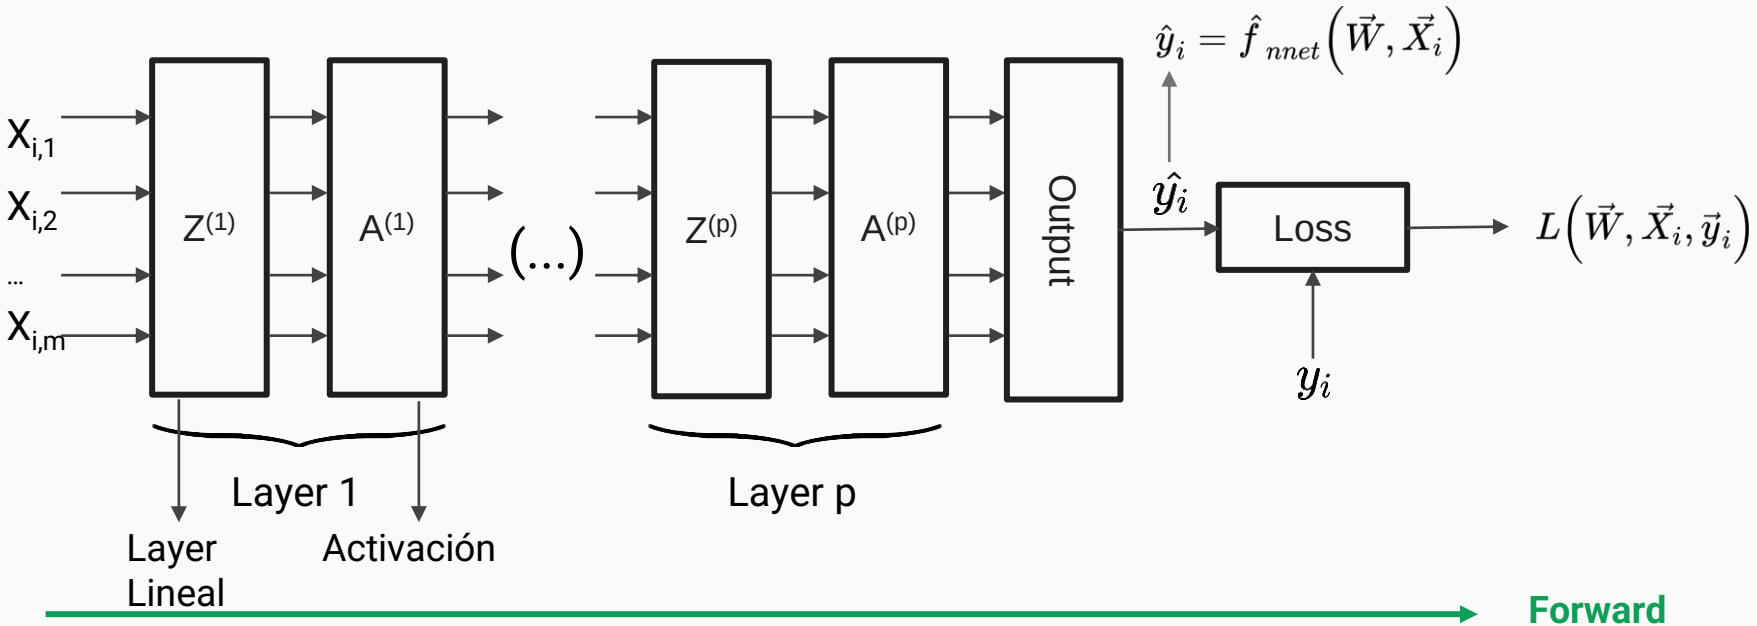

Resolvemos backpropagation en forma numérica: $\nabla_{\vec{W}} L \rightarrow \vec{W} = \vec{W} - \alpha \times \nabla_{\vec{W}} L$

Solución de XOR con red neuronal simple

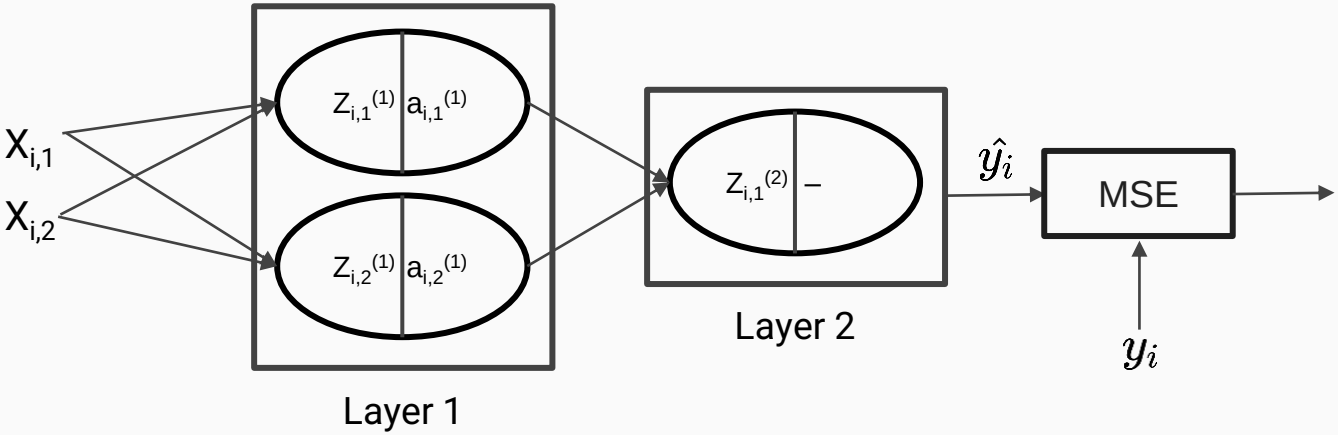

- Arquitectura de 2 layers: 1 layer hidden, 1 layer de salida
- 2 neuronas en layer 1, función de activación sigmoid
- 1 neurona layer 2, sin activación
- ¿Cuántos parámetros entreno?

$$\left.\begin{aligned} \vec{W}^{(1)} &\in R^{2\times 2} \rightarrow 4 \\ \vec{b}^{(1)} &\in R^{2\times 1} \rightarrow 2 \\ \vec{W}^{(2)} &\in R^{1\times 2} \rightarrow 2 \\ \vec{b}^{(2)} &\in R^{1} \rightarrow 1 \end{aligned}\right\} \text{9 parámetros}$$

Solución de XOR con red neuronal simple

- **Paso Forward:**

$$Z_{i,1}^{(1)} = W_{1,1}^{(1)} \cdot X_{i,1} + W_{1,2}^{(1)} \cdot X_{i,2} + b_1^{(1)}$$

$$Z_{i,2}^{(1)} = W_{2,1}^{(1)} \cdot X_{i,1} + W_{2,2}^{(1)} \cdot X_{i,2} + b_2^{(1)}$$

$$a_{i,1}^{(1)} = \sigma\left(Z_{i,1}^{(1)}\right)$$

$$a_{i,2}^{(1)} = \sigma\left(Z_{i,2}^{(1)}\right)$$

$$Z_{i,1}^{(2)} = W_{1,1}^{(2)} \cdot a_{i,1}^{(1)} + W_{1,2}^{(2)} \cdot a_{i,2}^{(1)} + b_1^{(2)}$$

$$\hat{y}_i = a_{i,1}^{(2)} = Z_{i,1}^{(2)}$$

$$L_{\vec{W}} = (y_i - \hat{y}_i)^2$$

Solución de XOR con red neuronal simple

- **Debo encontrar $W_1^{(1)}$, $b_1^{(1)}$, $W_2^{(1)}$, $b_2^{(1)}$, $W_1^{(2)}$, $b_1^{(2)}$. Utilizo SGD:**

> Inicializar los pesos $\vec{W} \rightarrow U(0,1) \rightarrow 9$ variables
>
> for epoch in range(n_epochs) :
>
> > for $\vec{X}_i, y_i$ in $(\vec{X}, \vec{y})$:
> >
> > (1)Forward $\rightarrow \hat{y}_i = \hat{f}_{nnet}\left(\vec{W}, \vec{X}_i\right)$
> >
> > (2)Error $\rightarrow e_i = (y_i - \hat{y}_i)^2$
> >
> > (3)Backward $\rightarrow \begin{cases} \partial L/\partial W_{1,1}^{(1)},\ \partial L/\partial W_{1,2}^{(1)}\ \partial L/\partial b_1^{(1)} \\ \partial L/\partial W_{2,1}^{(1)},\ \partial L/\partial W_{2,2}^{(1)},\ \partial L/\partial b_2^{(1)} \\ \partial L/\partial W_{1,1}^{(2)},\ \partial L/\partial W_{1,2}^{(2)},\ \partial L/\partial b_1^{(2)} \end{cases}$
> >
> > (4)Actualización $\rightarrow \begin{cases} W_{1,1}^{(1)} \leftarrow W_{1,1}^{(1)} - \alpha \cdot \partial L/\partial W_{1,1}^{(1)} \\ \dots \\ b_1^{(2)} \leftarrow b_1^{(2)} - \alpha \cdot \partial L/\partial b_1^{(2)} \end{cases}$
>
> > Calcular MSE $= \frac{1}{4}\sum_{i=1}^{4}(y_i - \hat{y}_i)^2$ ⟶ Loss plot
>
> Return $\vec{W}$

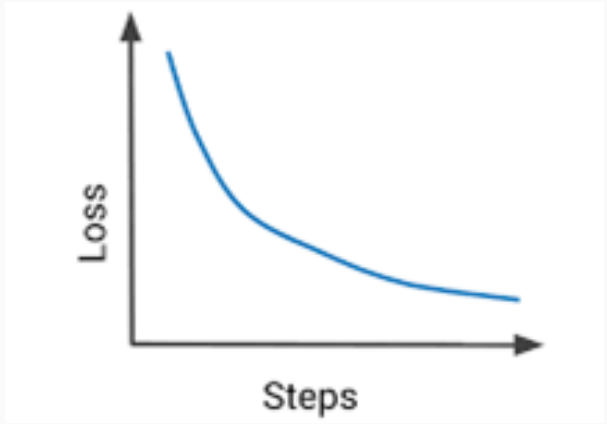

Solución de XOR con red neuronal simple

- **Backpropagation:**

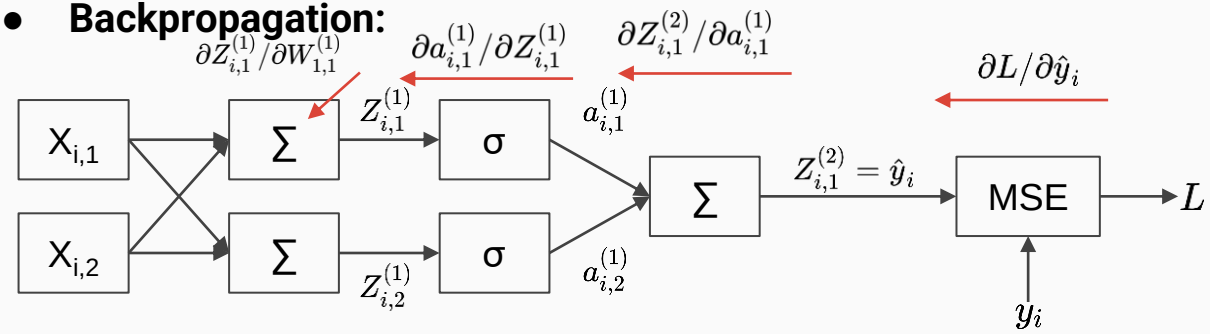

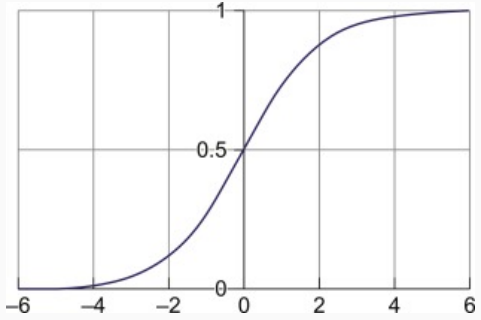

$$\sigma(x) = \frac{1}{1+e^{-x}} = \frac{e^x}{e^x+1}$$

$$\sigma'(x) = \sigma(x)\cdot(1-\sigma(x))$$

$$\partial L/\partial W^{(2)}_{1,1} = \frac{\partial}{\partial W^{(2)}_{1,1}}\left((y_i-\hat{y}_i)^2\right) = \partial L/\partial \hat{y}_i \cdot \partial \hat{y}_i/\partial W^{(2)}_{1,1} = 2\cdot(y_i-\hat{y}_i)\cdot -1\cdot a^{(1)}_{i,1}$$

$$\vdots$$

$$\partial L/\partial W^{(1)}_{1,1} = \partial L/\partial \hat{y}_i \cdot \partial \hat{y}_i/\partial a^{(1)}_{i,1} \cdot \partial a^{(1)}_{i,1}/\partial Z^{(1)}_{i,1} \cdot \partial Z^{(1)}_{i,1}/\partial W^{(1)}_{1,1} =$$

$$= -2\cdot(y_i-\hat{y}_i)\cdot W^{(2)}_{1,1}\cdot\sigma\left(Z^{(1)}_{i,1}\right)\cdot\left(1-\sigma\left(Z^{(1)}_{i,1}\right)\right)\cdot X_{i,1}$$

9 derivadas parciales!

EJERCICIO

1. Completar las 9 derivadas parciales.
2. Implementar en Python la solución de XOR con la red neuronal planteada en clase. Utilizar SGD.
3. Graficar MSE por epoch.